

Ingeniería del Conocimiento

Unidad 1

Fundamentos de Ingeniería del Conocimiento

Conceptos Nucleares

Conocimiento

Definición: Información estructurada que permite tomar decisiones, hacer inferencias y resolver problemas. Va más allá de datos o información porque incluye relaciones, contexto y aplicabilidad.

Tipos:

- **Declarativo** ("saber qué"): París es la capital de Francia
- **Procedimental** ("saber cómo"): Cómo montar en bicicleta
- **Condicional:** Si X entonces Y (reglas, causalidad)

Ejemplo ingenieril:

Dato: Temperatura = 38.5°C

Información: El paciente tiene fiebre

Conocimiento: Fiebre + síntomas respiratorios + temporada invernal
→ probable infección viral → tratamiento sintomático

Para recordar: El conocimiento te permite actuar apropiadamente ante situaciones nuevas pero similares.

Cognición

Definición: Conjunto de procesos mentales que permiten adquirir, procesar, almacenar y aplicar información para comprender el mundo, razonar y tomar decisiones adaptativas.

Procesos incluidos:

- Percepción (interpretar estímulos)
- Atención (seleccionar información relevante)
- Memoria (almacenar y recuperar)
- Razonamiento (inferencias lógicas/causales)
- Aprendizaje (modificar comportamiento por experiencia)
- Toma de decisiones

Diferencia clave con "funcionalidad cognitiva":

- Un GPS calcula rutas (funcionalidad cognitiva)
- Un humano entiende por qué esa ruta tiene sentido dado el contexto (cognición)

Ejemplo ingenieril:

- ChatGPT genera código coherente (funcionalidad cognitiva: generación)
 - Un programador senior entiende *por qué* ese código puede tener bugs sutiles (cognición: comprensión profunda)
-

Ciencia Cognitiva

Definición: Estudio interdisciplinario de la mente y los procesos cognitivos, combinando psicología, neurociencia, lingüística, filosofía, inteligencia artificial y antropología.

Objetivo: Entender CÓMO funciona la cognición (mecanismos, principios, limitaciones).

Métodos: Experimentos psicológicos, neuroimagen (fMRI), modelos computacionales, estudios de casos clínicos.

Relación con IA:

- Ciencia cognitiva → IA: Inspira arquitecturas (ej: atención, memoria de trabajo)
- IA → Ciencia cognitiva: Provee modelos computacionales para testear teorías

Ejemplo: ACT-R (arquitectura cognitiva) modela cómo humanos resuelven problemas matemáticos, prediciendo tiempos de respuesta y errores típicos.

Neurociencia

Definición: Estudio del sistema nervioso (cerebro, neuronas, circuitos) desde nivel molecular hasta comportamental.

Diferencia con ciencia cognitiva:

- Neurociencia: Enfoque biológico (¿qué regiones cerebrales se activan?)
- Ciencia cognitiva: Enfoque funcional (¿qué procesos computacionales ocurren?)

Relevancia para IA:

- ☒ Inspiración arquitectural (redes neuronales, procesamiento jerárquico)

- **✗** NO copiar literalmente (restricciones biológicas no aplican a hardware)

Ejemplo:

- Neurociencia: La corteza prefrontal se activa durante planificación
 - IA análoga: Módulo de planificación en un agente (pero sin simular neuronas)
-

Ingeniería del Conocimiento

Definición: Disciplina que diseña, construye y mantiene sistemas que capturan, representan y utilizan conocimiento para resolver problemas complejos.

Actividades clave:

1. **Adquisición:** Extraer conocimiento de expertos, datos, documentos
2. **Representación:** Modelar conocimiento (ontologías, grafos, reglas)
3. **Razonamiento:** Aplicar conocimiento para inferencias
4. **Validación:** Verificar consistencia y completitud

Diferencia con ciencia cognitiva:

- Ciencia cognitiva: "¿Cómo razonan los humanos?"
- Ingeniería del conocimiento: "¿Cómo construimos sistemas que razonen efectivamente?"

Ejemplo práctico: Construir un sistema experto para diagnóstico médico:

1. Entrevistar médicos (adquisición)
 2. Crear ontología de enfermedades, síntomas, tratamientos (representación)
 3. Implementar motor de inferencia (razonamiento)
 4. Testear contra casos reales (validación)
-

Cognición: Matices Importantes

Cognición Humana

Definición: Cognición tal como ocurre en seres humanos, con todas sus características específicas: embodiment (encarnación física), emoción, intuición, sesgos, creatividad, conciencia.

Características distintivas:

- Grounded en experiencia multimodal (visual, táctil, auditiva)
- Influenciada por estados emocionales y motivacionales
- Limitaciones específicas (memoria de trabajo: 7 ± 2 ítems)
- Capacidad de aprendizaje con pocos ejemplos (few-shot learning natural)
- Razonamiento causal intuitivo ("física ingenua", "psicología ingenua")

Ejemplo: Un niño de 3 años sabe que si empuja un vaso al borde de la mesa, caerá. Aprendió esto con pocas experiencias y generaliza a objetos nunca vistos. Un modelo de ML necesitaría miles de ejemplos de objetos cayendo.

Cognición Computacional

Definición: Uso de sistemas computacionales (algoritmos, IA, robots) para realizar tareas cognitivas o modelar procesos cognitivos.

Dos vertientes:

1. **Cognitiva:** Simular cognición humana (ej: ACT-R, SOAR)
2. **Funcional:** Resolver problemas cognitivos eficientemente sin copiar humanos (ej: Deep Blue)

Características:

- No requiere embodiment físico (puede ser puramente digital)
- Sin emociones, motivaciones intrínsecas (a menos que se programen)
- Diferentes limitaciones (velocidad de procesamiento, memoria, energía)
- Puede hacer cálculos exactos que humanos no pueden

Relación con cognición humana:

- Puede inspirarse en ella (neuro-inspired AI)
- Puede complementarla (cognición extendida)
- NO necesita replicarla (aviones no aletean)

Ejemplo: AlphaGo usa cognición computacional (redes neuronales + búsqueda MCTS) para jugar Go. No "piensa" como un humano, pero logra maestría comparable.

Funciones Cognitivas (Humanas y Computacionales)

Definición: Capacidades específicas que componen la cognición, implementables tanto en humanos como en sistemas computacionales.

Principales funciones:

Función	Humana	Computacional	Ejemplo IA
Percepción	Interpretar estímulos sensoriales	Procesamiento de señales (visión, audio)	CNN para clasificación de imágenes
Atención	Selección de información relevante	Mecanismos de atención (transformers)	Self-attention en BERT
Memoria	Almacenamiento y recuperación	Bases de datos, parámetros del modelo	RAG con vector database
Razonamiento	Inferencias lógicas/causales	Motores de inferencia, planificadores	Sistema experto, Prolog
Aprendizaje	Modificación por experiencia	Ajuste de parámetros (entrenamiento)	Backpropagation, RL
Lenguaje	Producción y comprensión lingüística	NLP, generación de texto	LLMs (GPT, Claude)
Toma de decisiones	Elección entre alternativas	Algoritmos de optimización	Reinforcement Learning

Importante: Que una IA implemente una función cognitiva NO implica que lo haga como un humano.

Arquitecturas y Sistemas

Arquitectura Cognitiva

Definición: Marco teórico y computacional que especifica los componentes, representaciones y procesos necesarios para la cognición general (no solo tareas específicas).

Características:

- **Integrada:** Múltiples funciones cognitivas coordinadas
- **General:** Aplicable a diversos dominios
- **Persistente:** Estado interno que se mantiene entre tareas
- **Teoría comprometida:** Basada en hipótesis sobre cómo funciona la cognición

Arquitecturas clásicas:

- **SOAR** (Laird et al.): Basada en resolución de problemas y aprendizaje chunking
- **ACT-R** (Anderson): Modelado cognitivo con módulos declarativos/procedimentales

- **CLARION (Sun):** Integra procesamiento implícito/explicito

Analogía: Si una función cognitiva es un órgano (corazón, pulmón), una arquitectura cognitiva es el organismo completo con todos los órganos coordinados.

Pregunta para ingenieros: ¿Un agente LLM con workflow (ReAct, AutoGPT) es una arquitectura cognitiva? Debate abierto en Sesión 3-4.

Ingeniería Cognitiva

Definición: Aplicación de principios de ciencia cognitiva al diseño de sistemas, interfaces y tecnologías que interactúan con humanos.

Diferencias con ingeniería del conocimiento:

- Ingeniería del conocimiento: Foco en representar/razonar sobre conocimiento
- Ingeniería cognitiva: Foco en cómo humanos interactúan con sistemas

Áreas de aplicación:

- Diseño de interfaces (UX/UI cognitivamente ergonómico)
- Human-computer interaction (HCI)
- Sistemas de soporte a la decisión
- Automatización con human-in-the-loop

Ejemplo: Diseñar un cockpit de avión considerando:

- Carga cognitiva del piloto (atención dividida)
 - Memoria de trabajo (no sobrecargar con información)
 - Toma de decisiones bajo presión (simplificar opciones críticas)
-

Sistema Cognitivo

Definición: Entidad (humana, artificial o híbrida) capaz de realizar procesos cognitivos de forma integrada y adaptativa.

Componentes típicos:

1. **Sensores/Percepciones:** Input del entorno
2. **Memoria:** Almacenamiento de conocimiento y experiencia
3. **Procesamiento:** Razonamiento, aprendizaje, decisiones
4. **Actuadores/Acciones:** Output que afecta el entorno

5. **Control:** Coordinación de componentes

Tipos:

- **Biológico:** Cerebro humano, animales
- **Artificial:** Agente IA, robot autónomo
- **Híbrido:** Humano + herramientas IA (cognición extendida)

Ejemplo práctico: Sistema autónomo de trading:

- Sensores: APIs de mercados financieros
- Memoria: Datos históricos, modelos entrenados
- Procesamiento: Predicción de precios, gestión de riesgo
- Actuadores: Ejecución de órdenes
- Control: Reglas de negocio, límites de pérdida

Consistencia del Sistema Cognitivo

Definición: Propiedad de un sistema cognitivo donde sus conocimientos, creencias, decisiones y acciones son coherentes entre sí y con sus objetivos, sin contradicciones lógicas.

Tipos de consistencia:

1. **Lógica:** No hay contradicciones formales
 - Ejemplo: Si el sistema "sabe" que $A \rightarrow B$ y A es verdadero, debe inferir B
2. **Temporal:** Decisiones coherentes a lo largo del tiempo
 - Ejemplo: Si ayer aprobó un crédito con perfil X, hoy no debe rechazar perfil idéntico sin razón
3. **Contextual:** Respuestas apropiadas según contexto
 - Ejemplo: Recomendaciones de productos coherentes con historial del usuario
4. **Multi-nivel:** Coherencia entre razonamiento de bajo y alto nivel
 - Ejemplo: Decisiones operativas alineadas con objetivos estratégicos

Problemas de inconsistencia en IA:

- LLMs pueden generar afirmaciones contradictorias en conversación larga
- Sistemas expertos con reglas conflictivas
- Modelos que aprenden sesgos inconsistentes con políticas éticas

Ejemplo de falla: Chatbot bancario que en un mensaje dice "puede retirar sin comisión" y en el siguiente (misma conversación) dice "retiros tienen comisión de 2%". Inconsistencia temporal que erosiona confianza.

Técnicas para garantizar consistencia:

- Verificación formal de reglas (sistemas simbólicos)
- Validación de salidas con constraints (neurosimbólico)
- Memory management en agentes (evitar contradicciones históricas)

Conceptos Relacionados

Aprendizaje

Definición: Proceso por el cual un sistema (humano o artificial) modifica su comportamiento, conocimiento o habilidades basándose en experiencia.

Tipos relevantes en IA:

Tipo	Descripción	Ejemplo IA
Supervisado	Aprender de ejemplos etiquetados	Clasificación de imágenes
No supervisado	Descubrir patrones sin etiquetas	Clustering de clientes
Por refuerzo	Aprender por recompensas/penalizaciones	AlphaGo, robots
Transfer	Aplicar conocimiento de un dominio a otro	Fine-tuning de LLMs
Few-shot	Aprender con pocos ejemplos	GPT-3 con prompts
Continuo	Aprendizaje incremental sin olvidar	Lifelong learning

Diferencia humano vs IA:

- Humanos: Aprenden con pocos ejemplos, generalizan ampliamente, olvidan selectivamente
- IA actual: Requiere muchos datos, generalización limitada, catastrófico olvido (forgetting)

Modelo

Definición: Representación simplificada de un sistema, proceso o fenómeno que captura sus aspectos esenciales para un propósito específico.

En contexto de IA:

1. **Modelo de ML:** Función matemática aprendida (ej: red neuronal entrenada)
2. **Modelo cognitivo:** Teoría computacional de un proceso mental (ej: modelo de memoria de trabajo)

3. **Modelo del mundo:** Representación interna que un sistema tiene del entorno

Características clave:

- **Abstracción:** Ignora detalles irrelevantes
- **Propósito:** Diseñado para tarea específica
- **Validación:** Debe ser testeado contra realidad

Ejemplo práctico: Un modelo de predicción de churn (cancelación de clientes):

- Input: Historial de compras, soporte, uso producto
- Output: Probabilidad de cancelación
- Simplificación: Ignora factores externos (economía, competencia)
- Validación: Precision, recall en datos de test

Relación con conocimiento:

- Un modelo puede *contener* conocimiento (implícitamente en pesos, explícitamente en reglas)
- Pero modelo $\neq$ conocimiento completo del dominio

Filosofía de la Ciencia Cognitiva

Definición: Rama de la filosofía que examina los fundamentos conceptuales, métodos y supuestos de la ciencia cognitiva.

Preguntas centrales:

- ¿Qué es la mente? ¿Es lo mismo que el cerebro?
- ¿Puede haber cognición sin conciencia?
- ¿La cognición es computación? (Hipótesis computacional de la mente)
- ¿Qué significa "entender" o "comprender"? (Chinese Room de Searle)
- ¿Puede una máquina "pensar"? (Test de Turing)

Debates relevantes para IA:

1. Funcionalismo vs Materialismo:

- Funcionalismo: La cognición es definida por su función, no su sustrato (software)
- Materialismo: La cognición requiere sustrato físico específico (hardware)
- Implicación IA: ¿Puede una IA en silicio tener cognición equivalente a cerebro biológico?

2. Strong AI vs Weak AI (Searle):

- Strong AI: Máquinas pueden tener estados mentales genuinos (comprensión real)
- Weak AI: Máquinas solo simulan cognición (sin comprensión)
- Ejemplo: Chinese Room (sistema sigue reglas sintácticas sin entender semántica)

3. Embodied cognition:

- Cognición requiere cuerpo físico que interactúa con entorno
- Desafío: ¿LLMs puramente textuales pueden tener cognición genuina?

4. Mente extendida (Clark & Chalmers):

- Cognición no se limita al cerebro, incluye herramientas externas
- Implicación IA: Calculadora, smartphone, RAG son extensiones cognitivas

Relevancia para ingenieros: No necesitan resolver estos debates filosóficos, pero SÍ deben posicionarse sobre:

- ¿Su sistema debe ser autónomo o herramienta?
- ¿Qué significa "éxito" para su aplicación? (precisión técnica vs utilidad percibida)
- ¿Cómo diseñar interacción humano-IA? (delegación vs colaboración)